以 C1 看独立引擎的优化演进

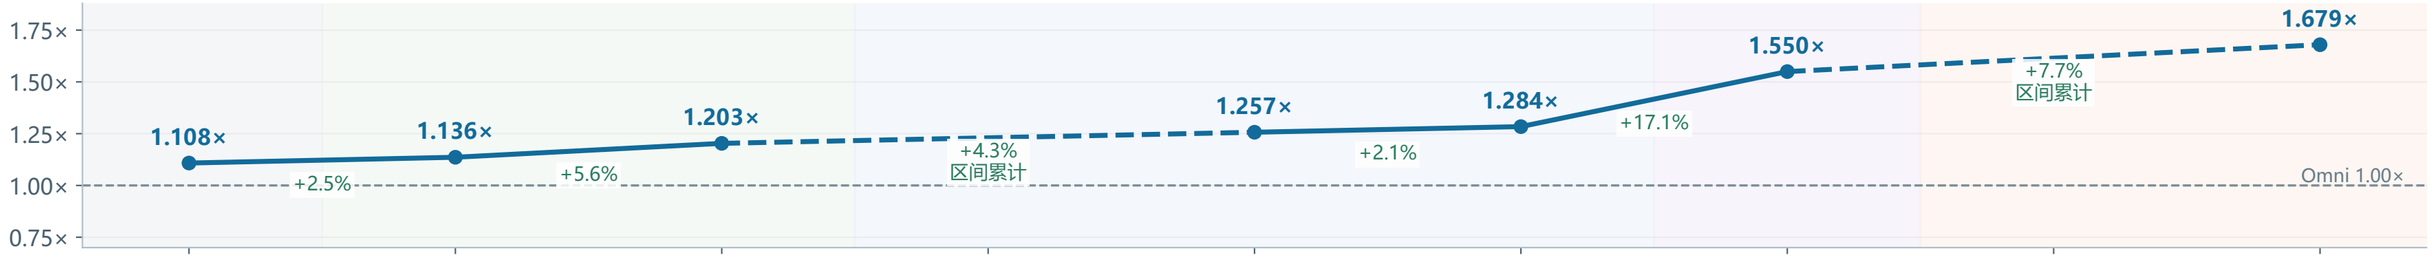
固定 vLLM-Omni main@9990f10d9 的 C1 = 1.00×，纵轴均为越高越好

单 Ascend 910B1 / A2 ｜ 官方 CLI · 每个源运行 32 请求 ｜ 七个实测阶段 · 两处缺测

初版 | RSI 机制适配 | profiling + 自主策略 | 6层profiling 诊断 | 持续 profiling / 后续 40 轮

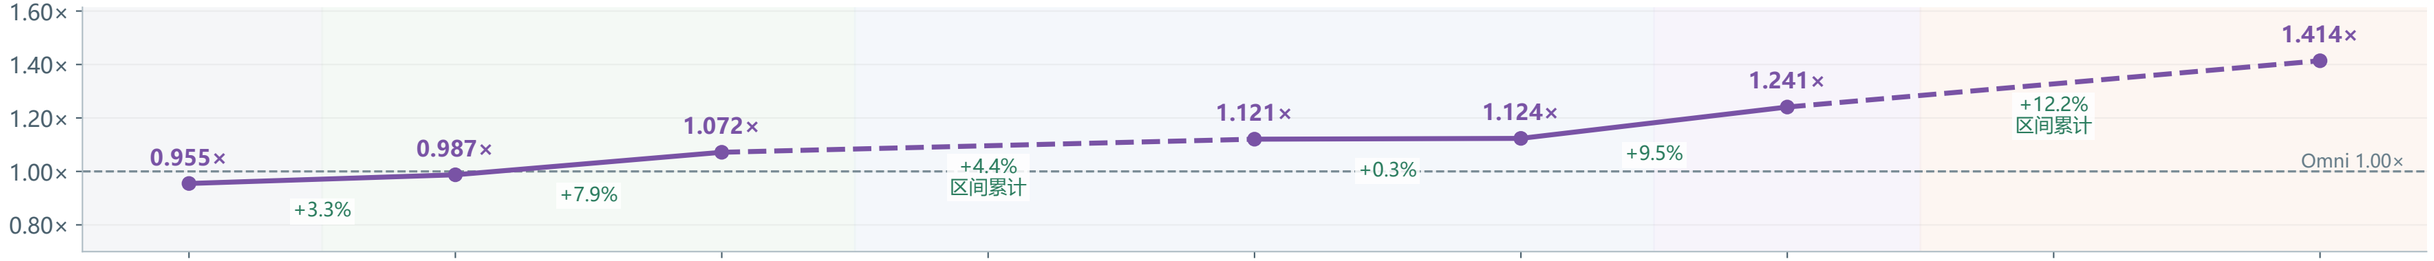
首包速度倍数 • Omni TTFP / 引擎 TTFP

782.50 → 516.35 ms　累计降低 34.0%



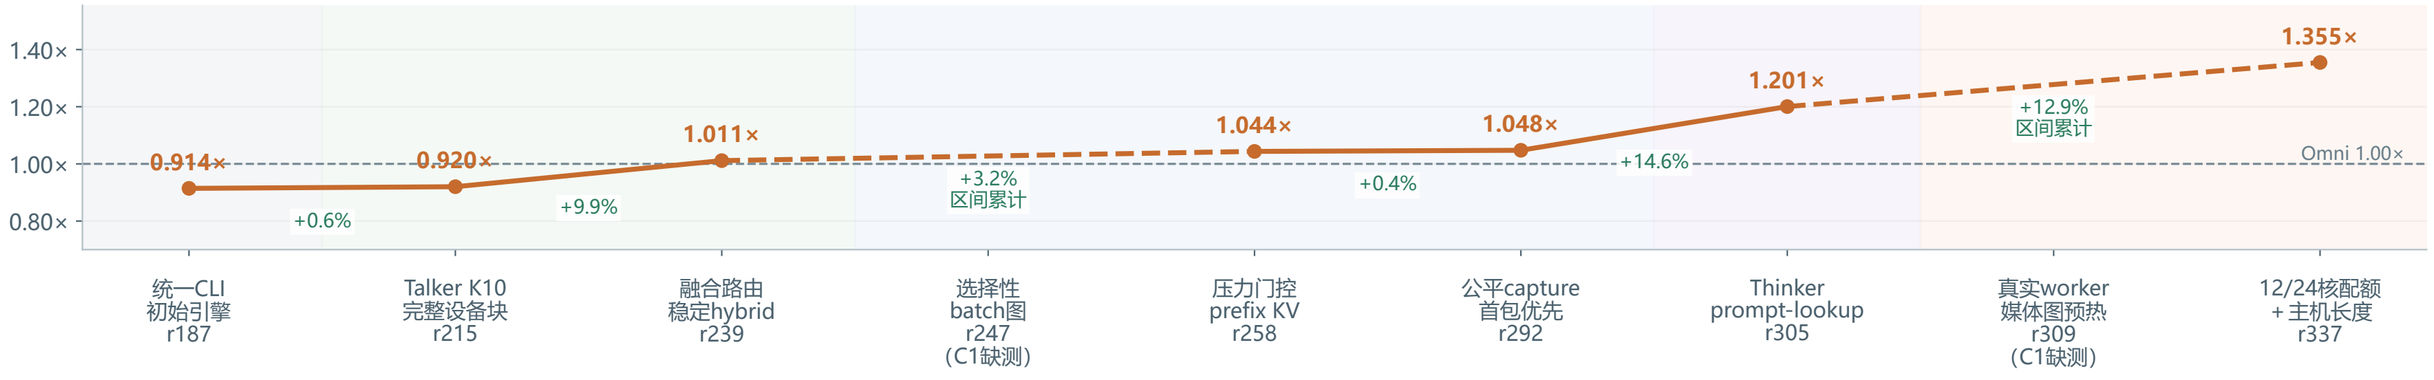
RTF 效率倍数 • Omni RTF / 引擎 RTF

0.3261 → 0.2202　累计降低 32.5%



请求吞吐倍数 • 引擎 request/s / Omni request/s

0.7325 → 1.0855 request/s　累计提高 48.2%



累计演进的关键优化阶段

实线连接相邻实测阶段，虚线跨越缺测阶段。边注为前后实测端点变化，跨缺测标注为区间累计。
r247、r309 未归档独立 C1 测量。r337 取两次 C1 均值，其余有值阶段各取一次原生观测。
跨日期端点包含组合改动和运行波动。前置 r32–r181 迁移与旧协议建设详见完整账本。
Flow 引擎 FP16 / 6步，Omni FP32 / 10步，RNG 与音频时长不同。完整语音质量门待完成。