以 C8 看独立引擎的完整优化历程

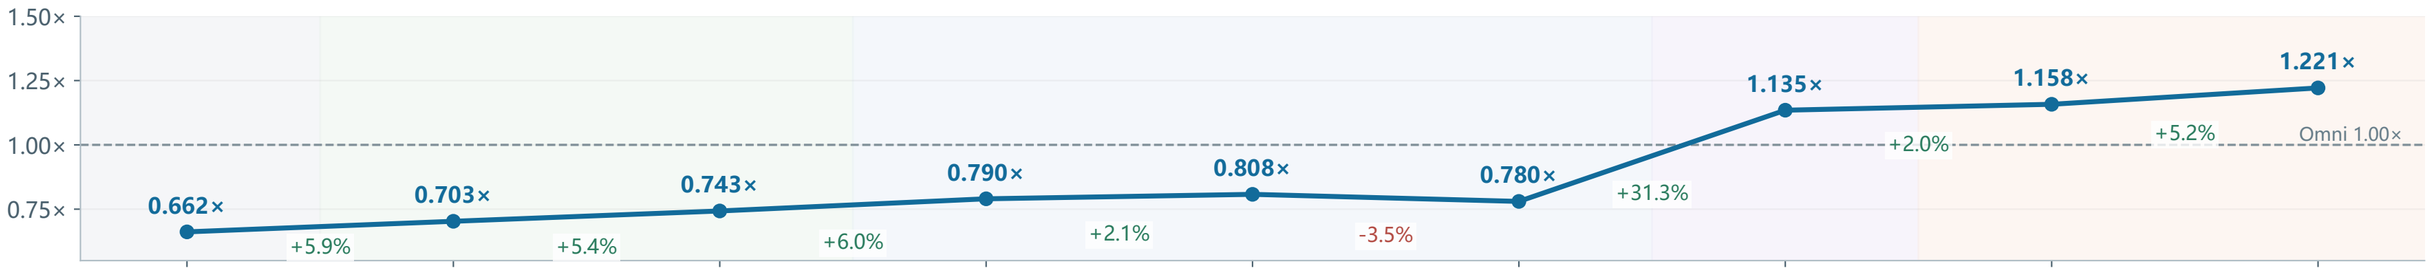
固定本次 vLLM-Omni main@9990f10d9 的 C8 = 1.00×，纵轴均为越高越好

单 Ascend 910B1 / A2 ｜ 官方 CLI · 每个源运行 128 请求 ｜ 边注显示相邻阶段收益

初版 | RSI 机制适配 | profiling + 自主策略 | 6层profiling 诊断 | 持续 profiling / 后续 40 轮

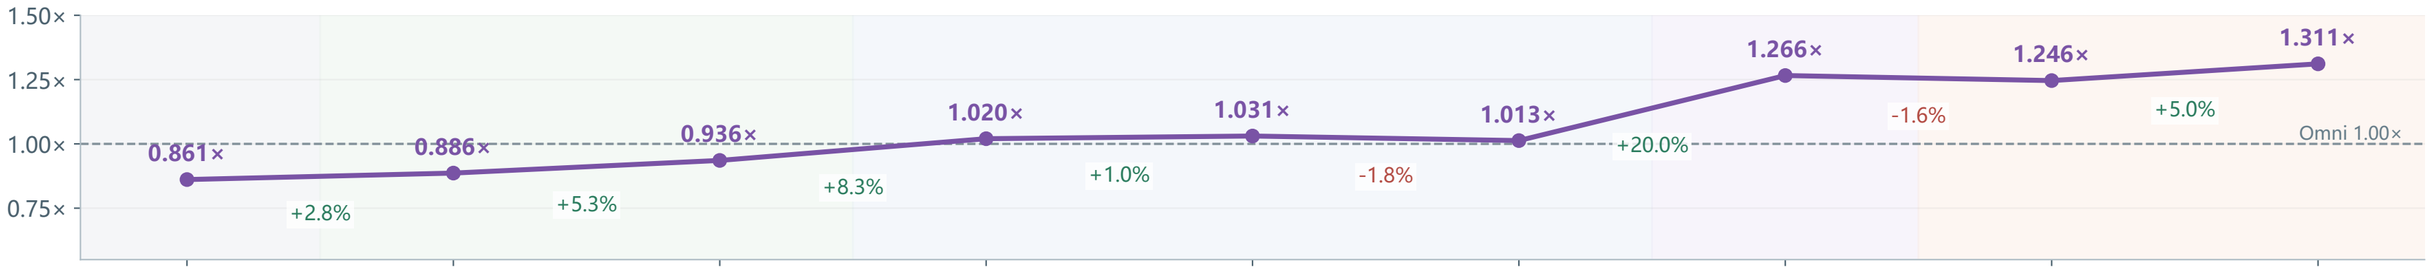
首包速度倍数 • Omni TTFP / 引擎 TTFP

3097.8 → 1678.2 ms　累计降低 45.8%



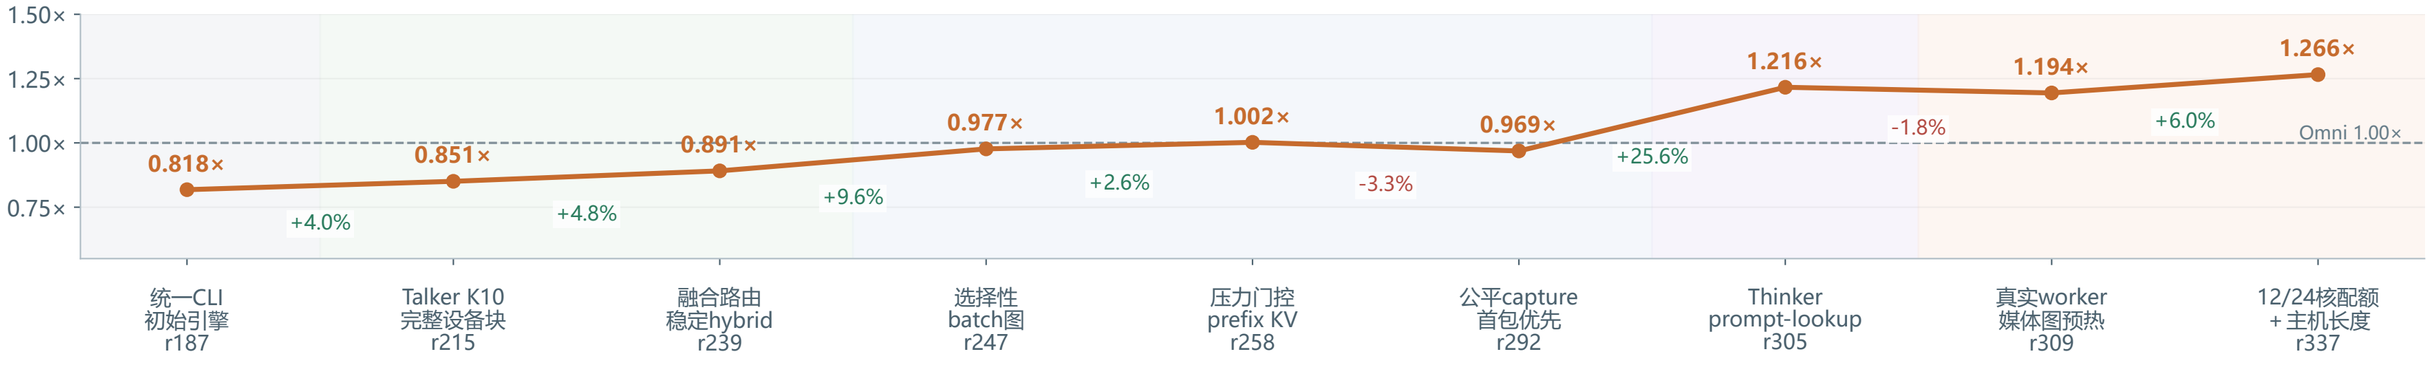
RTF 效率倍数 • Omni RTF / 引擎 RTF

1.1883 → 0.7805　累计降低 34.3%



请求吞吐倍数 • 引擎 request/s / Omni request/s

1.6063 → 2.4851 request/s　累计提高 54.7%



累计演进的关键优化阶段

边注为相邻端点的 TTFP / RTF 降低或 request/s 提高。跨日期端点包含组合改动和运行波动。
r309 取最终窗口三次控制均值，r337 取两次候选均值。r292 的 C8 回退与 r309 的混合结果如实保留。
前置 r32–r181 完成 NPU 迁移与旧协议建设，详见完整账本。当前图从统一官方 CLI 的 r187 开始。
Flow 引擎 FP16 / 6步，Omni FP32 / 10步，RNG 与生成音频时长不同。完整语音质量门待完成。