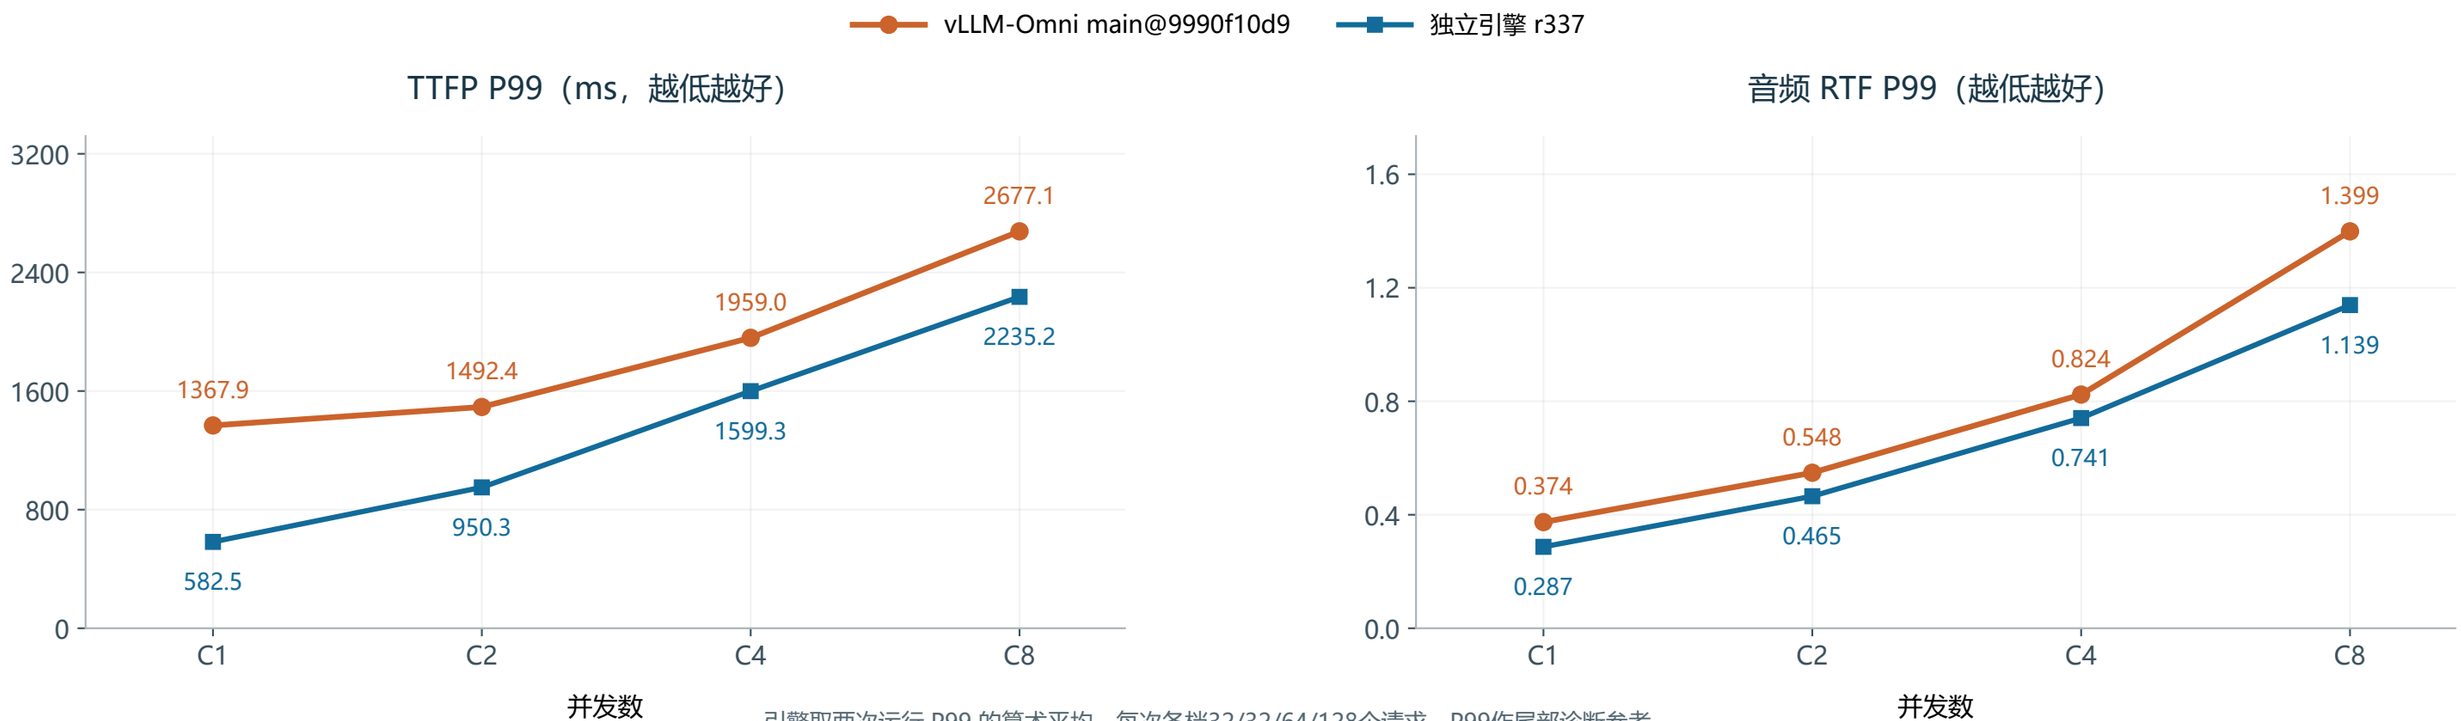
独立引擎 vs vLLM-Omni • 样本 P99

单卡 Ascend 910B1（A2） | 官方客户端 5917730a | chunk25 | C1/C2/C4/C8 = 32/32/64/128 请求



引擎取两次运行 P99 的算术平均。每次各档32/32/64/128个请求，P99作尾部诊断参考。

引擎每档指标取两次测量的算术平均。橙线为 Omni 基线，蓝线为独立引擎 r337。
Flow 引擎 FP16 / 6步，Omni FP32 / 10步。RNG实现及生成音频时长不同。
C1 为后补测量。C2/C4/C8 沿用此前完成的同配置测量。
完整语音质量门待完成，评估迁至 Omni NPU 环境。